

LAPORAN TEKNIS DATA SCIENTIST PROYEK CAPSTONE CAREERLENS

Disusun oleh:

Nama	ID
Sevilla Claudia Depari	CDCC319D6X0996
Pyta Nur Chumairah	CDCC208D6X1680

1. Problem Discovery

1.1 Latar Belakang

Berdasarkan laporan terbaru dari Badan Pusat Statistik (BPS) per Agustus 2025, tercatat bahwa Tingkat Pengangguran Terbuka (TPT) untuk lulusan universitas berada di angka 4,85% (*Badan Pusat Statistik, 2025*). Di sisi lain, banyak individu bekerja di bidang yang tidak sesuai dengan latar belakang pendidikannya. Jika dilihat lebih dalam, kondisi ini bukan semata karena kurangnya kemampuan. Banyak lulusan sebenarnya sudah memiliki skill dasar, namun seringkali bingung bagaimana mengonversi skill tersebut agar relevan dengan kebutuhan industri (*TALENT Universal, 2025*).

1.2 Problem Statement

Berdasarkan permasalahan tersebut, terdapat beberapa tantangan yang ingin diselesaikan dalam proyek ini. Pertama, belum adanya mekanisme yang dapat membantu pengguna mengukur tingkat kecocokan skill dan minat karir terhadap berbagai pekerjaan/role secara objektif. Kedua, pengguna seringkali tidak mengetahui alur pembelajaran yang tepat untuk menutup kesenjangan skill yang dimiliki dengan kebutuhan industri. Oleh karena itu, diperlukan pendekatan berbasis data yang mampu memberikan rekomendasi karir sekaligus roadmap upskilling yang lebih terarah.

1.3 Tujuan Analisis Data

Analisis data ini bertujuan untuk memetakan kesenjangan kompetensi, serta membangun model rekomendasi karir berbasis minat, keahlian (skill), dan analisis RIASEC. Selain itu, proyek ini bertujuan memberikan panduan langkah nyata bagi pengguna untuk meningkatkan kualitas diri agar sesuai dengan standar industri.

2. Data Collection

2.1 Alasan Membangun Dataset Mandiri

Tidak tersedia dataset tunggal yang tersedia secara publik yang mampu mengintegrasikan informasi pekerjaan/role, skill industri, alur pembelajaran, dan pemetaan kepribadian RIASEC (Holland Code Theory (RIASEC)," n.d.,) sekaligus sesuai dengan kebutuhan proyek capstone kami. Oleh karena itu, tim melakukan pengumpulan dan kurasi data dari berbagai sumber, seperti Kaggle, Indeed, O*NET, Coursera, Udemy, edX, dan Dicoding, kemudian menyusunnya kembali menjadi dataset terstruktur yang disesuaikan dengan kebutuhan sistem rekomendasi CareerLens.

2.2 Sumber Data

Sumber data yang digunakan dalam proyek ini berasal dari tiga platform, yaitu:

1. Kaggle: Digunakan untuk mengambil dataset terkait jenis pekerjaan/role, skill yang dibutuhkan untuk setiap jenis pekerjaan/role, dan sumber belajar (learning resources).
2. Indeed: Digunakan untuk mengambil informasi rata-rata gaji per bulan tiap jenis pekerjaan/role pada tahun 2026.
3. O*NET (Occupational Information Network): Digunakan sebagai sumber referensi standar internasional untuk memetakan hubungan antara peran pekerjaan (job roles) dengan karakteristik kepribadian/minat berdasarkan teori RIASEC.
4. Coursera, Udemy, edX, Dicoding: Digunakan untuk scraping data sumber pembelajaran (learning resources) untuk upskilling roadmap.

2.3 Struktur Dataset

Proses pengumpulan data dari berbagai sumber di atas menghasilkan empat dataset mentah utama yang diimpor pertama kali ke dalam notebook. Struktur dari keempat dataset tersebut adalah sebagai berikut:

1. `master_roles_df`: Dataset yang berfungsi sebagai basis data utama untuk memetakan nama peran pekerjaan/roles, kategori bidang, deskripsi pekerjaan/role, skill yang dibutuhkan, dan informasi gaji.
2. `roles_df`: Dataset yang memuat pemetaan antara pekerjaan/role dengan kecocokan karakteristik psikometris berdasarkan skor RIASEC.
3. `learning_resources_df`: Dataset yang berisi daftar jalur pembelajaran, materi, atau kursus yang relevan untuk membantu pengguna menguasai skill yang dibutuhkan pekerjaan/role tertentu.
4. `dummy_project_df`: Dataset yang menyediakan informasi proyek atau portofolio buatan yang dapat dikerjakan oleh pengguna sebagai simulasi kerja nyata.

3. Data Understanding

3.1 Dataset Overview

Bagian ini memberikan gambaran umum mengenai dimensi (jumlah baris dan kolom) serta tipe data dari masing-masing dataset:

- `master_roles_df`: Terdiri dari 68 baris dan 6 kolom. Dataset ini didominasi oleh tipe data object/string untuk deskripsi pekerjaan/role, skill yang dibutuhkan, dan informasi gaji.
- `roles_df`: Terdiri dari 68 baris dan 9 kolom. Dataset ini terdiri dari tipe data object untuk nama pekerjaan/role dan float untuk setiap skor RIASEC.
- `learning_resources_df`: Terdiri dari 978 baris dan 7 kolom. Dataset ini didominasi oleh tipe data object/string untuk nama skill, link course, tipe, dan platform.
- `dummy_projects_df`: Terdiri dari 68 baris dan 5 kolom. Dataset ini didominasi oleh tipe data object/string untuk deskripsi proyek buatan

seperti kasus, instruksi, dan tools yang dibutuhkan untuk mengerjakan proyek tersebut.

3.2 Data Dictionary

Untuk memahami informasi yang disimpan, berikut adalah kamus data (penjelasan kolom) dari variabel-variabel di setiap dataset:

a. master_roles_df

Nama Kolom	Tipe Data	Deskripsi
role_id	object	ID unik untuk setiap pekerjaan/role.
bidang	object	Kategori rumpun industri dari pekerjaan/role (terhubung pada database fields).
nama_role	object	Nama pekerjaan/role.
deskripsi	object	Penjelasan singkat mengenai tanggung jawab dan tugas dari peran pekerjaan/role.
skill	object	Kumpulan keahlian/skill yang wajib dikuasai untuk pekerjaan/role terkait.
gaji	object	Informasi gaji setiap pekerjaan/role terkait.

b. roles_df

Nama Kolom	Tipe Data	Deskripsi
role_id	object	ID unik untuk setiap pekerjaan/role.
field_id	object	ID unik untuk kategori rumpun industri dari pekerjaan/role (terhubung pada database fields).
role_name	object	Nama pekerjaan/role.
R	float	Skor kode R (Realistic)
I	float	Skor kode I (Investigative)
A	float	Skor kode A (Artistic)
S	float	Skor kode S (Social)
E	float	Skor kode E (Enterprising)
C	float	Skor kode C (Conventional)

c. learning_resources_df

Nama Kolom	Tipe Data	Deskripsi
resource_id	object	ID unik untuk setiap sumber pembelajaran.

role_id	object	ID unik untuk setiap pekerjaan/role.
step_number	int	Langkah pada alur pembelajaran.
nama_skill	object	Nama keahlian/skill yang wajib dikuasai untuk pekerjaan/role terkait.
link_course	object	Sumber pembelajaran/course
tipe	object	Tipe sumber pembelajaran.
platform	object	Platform sumber pembelajaran.

d. dummy_projects_df

Nama Kolom	Tipe Data	Deskripsi
project_id	object	ID unik untuk setiap dummy project.
role_id	object	ID unik untuk setiap pekerjaan/role.
judul_project	object	Judul setiap dummy project.
brief_cases	object	Deskripsi kasus dummy project.
instructions	object	Instruksi pengerjaan dummy project.
tools_used	object	Tools yang digunakan untuk membangun

		dummy project terkait.
--	--	------------------------

3.3 Data Quality Check

Berdasarkan pemeriksaan awal terhadap dataset, tidak ditemukan missing values maupun duplikasi data karena proses kurasi dilakukan secara manual selama tahap pengumpulan data. Namun, ditemukan beberapa kondisi yang memerlukan penyesuaian agar data siap dianalisis, yaitu:

1. Ketidaksetaraan Format Gaji: Kolom gaji masih berupa teks (object) dengan karakter non-numerik, sehingga tidak bisa digunakan untuk perhitungan statistik.
2. Struktur Skill (Keahlian) Tergabung: Kolom skill pada `master_roles_df` masih berbentuk string tunggal yang menggabungkan beberapa keahlian sekaligus dalam satu sel, sehingga sulit untuk dihitung frekuensi kemunculannya.

4. Data Cleaning & Transformation

Pada tahap ini dilakukan pembersihan dan transformasi data untuk memastikan data memiliki format yang konsisten dan siap digunakan pada tahap eksplorasi data (EDA). Karena dataset telah melalui proses kurasi manual saat pengumpulan data, tidak ditemukan missing values maupun duplikasi data. Oleh sebab itu, tahap ini lebih berfokus pada standarisasi format data agar dapat diproses secara statistik dan komputasional.

4.1 Transformasi kolom 'gaji'

Kolom 'gaji' pada `master_roles_df` masih berbentuk teks (object/string) dengan format mata uang, seperti:

Rp 9.116.248

Rp 4.500.000

Format tersebut tidak dapat langsung digunakan untuk operasi statistik seperti perhitungan rata-rata, median, atau visualisasi distribusi data.

Transformasi dilakukan untuk mengubah format gaji menjadi tipe numerik (integer) agar dapat dianalisis lebih lanjut pada tahap EDA.

Langkah yang dilakukan:

- Menghapus simbol "Rp"
- Menghapus tanda titik (.)
- Menghapus whitespace/spasi
- Mengubah tipe data menjadi integer

Contoh transformasi:

Sebelum	Sesudah
Rp 9.116.248	9116248
Rp 4.500.000	4500000

Cuplikan kode:

```
def konversi_gaji(teks):  
    # Cek apakah datanya kosong  
    if pd.isna(teks):  
        return np.nan  
  
    # Ubah menjadi string  
    teks = str(teks)  
  
    # Mencari semua yang bukan angka dan menghapusnya  
    angka_str = re.sub(r'\D', '', teks)  
  
    # Mengubah angka menjadi integer  
    if angka_str:  
        return int(angka_str)  
    else:  
        return np.nan  
  
# Menerapkan Fungsi ke Kolom gaji  
master_roles_df['gaji']  
master_roles_df['gaji'].apply(konversi_gaji)
```

Setelah transformasi dilakukan, kolom gaji berhasil diubah menjadi tipe data numerik (int64) sehingga dapat digunakan untuk analisis statistik dan visualisasi.

4.2 Transformasi dan Memecah kolom 'skill'

Kolom skill pada master_roles_df masih berbentuk string gabungan yang memuat beberapa skill dalam satu sel.

Contoh:

SQL, Java, Python, Git, JavaScript, HTML, CSS, React, Agile, Docker
Standarisasi dilakukan agar seluruh skill memiliki format yang konsisten dan dapat diproses pada tahap feature engineering.

Langkah yang dilakukan:

- Memecah daftar skill yang berbentuk string menjadi format list berdasarkan tanda koma.
- Menghapus spasi berlebih (whitespace) di awal dan akhir setiap kata di dalam list.
- Melakukan transformasi .explode() untuk mengurai setiap elemen skill di dalam list menjadi baris terpisah.

Contoh transformasi:

Sebelum	Sesudah
"SQL, Java, Python, Git, JavaScript, HTML, CSS, React, Agile, Docker"	['SQL', 'Java', 'Python', 'Git', 'JavaScript', 'HTML', 'CSS', 'React', 'Agile', 'Docker']

Cuplikan kode:

```
# Memecah skill menjadi list
master_roles_df['skill'] = master_roles_df['skill'].apply(
    lambda x: x if isinstance(x, list) else x.split(',')
)

# Menghapus spasi berlebih
master_roles_df['skill'] = master_roles_df['skill'].apply(
    lambda x: [s.strip() for s in x]
```

```

)
# Memecah setiap skill menjadi baris terpisah
skills_exploded = master_roles_df.explode('skill')

# Menghitung frekuensi skill
skill_counts = skills_exploded['skill'].value_counts().head(15)
skill_counts

```

Setelah transformasi dilakukan, kolom skill memiliki format yang lebih konsisten sehingga mempermudah proses eksplorasi skill.

4.3 Transformasi dan Memecah kolom 'tools_used'

Kolom tools_used pada master_roles_df masih berbentuk string gabungan yang memuat beberapa skill dalam satu sel.

Contoh:

Java; Spring Boot; MySQL

Standarisasi dilakukan agar seluruh tools memiliki format yang konsisten dan dapat digunakan pada tahap eksplorasi data.

Langkah yang dilakukan:

- Memecah daftar tools_used yang berbentuk string menjadi format list berdasarkan tanda delimiter.
- Menghapus spasi berlebih (whitespace) di awal dan akhir setiap kata di dalam list.
- Melakukan transformasi .explode() untuk mengurai setiap elemen tools_used di dalam list menjadi baris terpisah.

Contoh transformasi:

Sebelum	Sesudah
Java; Spring Boot; MySQL	[Java', 'Spring Boot', 'MySQL']

Cuplikan kode:

```

# Memecah tools_used menjadi list
dummy_projects_df['tools_used']
dummy_projects_df['tools_used'].apply(

```

```

        lambda x: ';'.join(x).split(';') if isinstance(x, list) else
x.split(';')
    )

    # Menghapus spasi berlebih
    dummy_projects_df['tools_used'] =
dummy_projects_df['tools_used'].apply(
    lambda x: [s.strip() for s in x]
)
dummy_projects_df['tools_used'].head(10).tolist()
# Memecah setiap tools menjadi baris terpisah
tools_exploded = dummy_projects_df.explode('tools_used')

# Menghitung frekuensi tools
tools_counts = tools_exploded['tools_used'].value_counts().head(15)
tools_counts

```

Setelah transformasi dilakukan, kolom `tools_used` memiliki format yang lebih konsisten sehingga mempermudah proses eksplorasi.

5. Exploratory Data Analysis (EDA)

Pada tahap ini dilakukan eksplorasi terhadap dataset untuk memahami pola, distribusi, dan karakteristik data yang dapat mendukung pengembangan sistem rekomendasi karir dan roadmap upskilling. Analisis ini dilakukan untuk memperoleh insight awal mengenai kebutuhan industri, karakteristik pekerjaan/role, distribusi sumber pembelajaran, serta pola kecenderungan minat berdasarkan pendekatan RIASEC.

5.1 Analisis Gaji

Eksplorasi pada bagian ini berfokus untuk memahami distribusi gaji di berbagai peran pekerjaan yang ada dalam dataset. Analisis dilakukan menggunakan statistik deskriptif dan visualisasi distribusi untuk melihat persebaran nilai gaji, serta mendeteksi adanya outlier yang mungkin muncul pada pekerjaan/role tertentu.

Analisis yang dilakukan:

1. Statistik deskriptif kolom gaji

Berdasarkan hasil statistik deskriptif terhadap kolom gaji, diperoleh ringkasan sebagai berikut:

count	68
mean	8,098,626
std	3,824,105
min	3,000,000
25%	5,111,778
50%	7,574,323
75%	9,796,166
max	27,264,928


Interpretasi:

Berdasarkan hasil statistik deskriptif, rata-rata gaji pada berbagai pekerjaan/role berada pada kisaran Rp 8,09 juta per bulan, dengan median sebesar Rp 7,57 juta. Hal ini menunjukkan bahwa sebagian besar pekerjaan dalam dataset berada pada rentang menengah hingga tinggi.

Selain itu, nilai maksimum yang mencapai Rp 27,2 juta menunjukkan adanya variasi gaji yang cukup besar antar role. Variasi ini kemungkinan dipengaruhi oleh spesialisasi skill maupun kompleksitas peran suatu pekerjaan/role.

2. Deteksi outlier menggunakan boxplot

Untuk memahami distribusi gaji lebih lanjut, dilakukan visualisasi menggunakan boxplot guna mendeteksi adanya nilai ekstrem (outlier).



Interpretasi:

Berdasarkan visualisasi boxplot, ditemukan beberapa nilai gaji yang berada di luar rentang mayoritas data (outlier). Namun, nilai tersebut tidak dihapus karena mempresentasikan kondisi industri yang realistis, seperti pekerjaan dengan spesialisasi tinggi yang memang memiliki kompensasi lebih besar dibanding pekerjaan/role lainnya.

3. Analisis gaji berdasarkan bidang


Untuk memahami bagaimana distribusi gaji di berbagai bidang, dilakukan analisis agregasi dengan menghitung rata-rata gaji pada setiap rumpun bidang. Data bidang pada dataset ini direpresentasikan dalam bentuk ID (field_id) yang merujuk pada pemetaan sebagai berikut:

- F01: Teknologi Informasi & Software Development
- F02: Data Science & Artificial Intelligence
- F03: Desain Kreatif & UI/UX
- F04: Digital Marketing & Analytics

Berikut tabel rata-rata gaji pada setiap rumpun bidang:

field_id	Nama Rumpun Bidang	gaji
F02	Data Science & Artificial Intelligence	11,044,787
F01	Teknologi Informasi & Software Development	7,990,243
F04	Digital Marketing & Analytics	6,226,700
F03	Desain Kreatif & UI/UX	6,184,094

Untuk memberikan gambaran perbandingan visual yang lebih jelas, berikut grafik batang rata-rata gaji:




Interpretasi:

Berdasarkan tabel di atas, rumpun bidang F02 (Data Science & Artificial Intelligence) menawarkan rata-rata gaji tertinggi yang menyentuh angka Rp

11,04 juta per bulan. Posisi kedua ditempati oleh bidang F01 (Teknologi Informasi & Software Development) dengan rata-rata Rp 7,9 juta per bulan. Sementara itu, rumpun bidang F03 (Desain Kreatif & UI/UX) dan F04 (Digital Marketing & Analytics) berada di rentang yang lebih rendah, masing-masing kisaran Rp 6,1 juta - 6,2 juta. Insight ini memberikan konfirmasi bahwa rumpun karir digital secara statistik berpotensi memberikan imbalan finansial yang jauh lebih besar.

4. Analisis role dengan gaji tertinggi

Untuk menjawab pertanyaan bisnis mengenai peran pekerjaan apa saja yang menawarkan gaji tertinggi di industri, berikut visualisasi grafik batang dari 10 posisi teratas:



Interpretasi:

Bar chart di atas menunjukkan 10 posisi pekerjaan yang menawarkan estimasi gaji tertinggi di dalam dataset. Guna mempermudah pembacaan grafik, berikut adalah pemetaan untuk beberapa ID (Role) yang menduduki posisi teratas:

- R040: Data Modeler
- R026: Solution Architect
- R033: Product Analyst

Terlihat bahwa role R040 (Data Modeler) menduduki peringkat teratas. Insight ini menegaskan bahwa pekerjaan/role yang membutuhkan skill dengan kompleksitas yang lebih tinggi cenderung dihargai lebih mahal oleh industri.

5.2 Analisis Skill


Eksplorasi pada bagian ini berfokus untuk memetakan kompetensi apa saja yang paling dibutuhkan oleh industri berdasarkan pada data pekerjaan/role. Analisis ini membantu mengidentifikasi skill dominan yang dapat menjadi dasar dalam rekomendasi karir ini.

Analisis yang dilakukan:

1. Jumlah kemunculan setiap skill (sample = 10)

skill	count
Python	32
SQL	20
Figma	8
Java	8
Excel	8
Google Analytics	7
Tableau	7
AWS	7
Power BI	6
CSS	6

Untuk memberikan gambaran perbandingan visual yang lebih jelas, berikut grafik batang 10 skill teratas:



Interpretasi:

Berdasarkan hasil eksplorasi, Python menjadi skill dengan jumlah kemunculan tertinggi, yaitu sebanyak 32 kali, diikuti SQL, 20 kali. Hal ini menunjukkan bahwa kemampuan pemrograman dan pengolahan data masih menjadi keahlian yang paling banyak dibutuhkan pada berbagai pekerjaan/role di industri digital. Selain itu, munculnya skill seperti Figma, Google Analytics, AWS, dan Power BI memperlihatkan bahwa industri juga membutuhkan kombinasi kemampuan desain, cloud computing, serta analisis data. Temuan ini menunjukkan bahwa beberapa skill bersifat lintas role dan dapat dijadikan fondasi awal dalam proses rekomendasi karir.

2. Jumlah skill tiap pekerjaan/role (sample = 5)

role_id	jumlah_skill
R001	10
R002	10
R003	10

R004	10
R005	10

Interpretasi:

Berdasarkan hasil eksplorasi, jumlah skill pada setiap pekerjaan/role cenderung konsisten, yaitu sebanyak 10 skill per role. Ini menunjukkan bahwa dataset telah dikurasi dengan struktur yang seragam. Namun, karena tidak terdapat variasi jumlah skill antar role, analisis lebih lanjut difokuskan pada frekuensi skill yang muncul, bukan jumlah skill tiap pekerjaan/role.

5.3 Analisis RIASEC

Eksplorasi ini bertujuan untuk melihat kecenderungan tipe kepribadian dan minat bakat yang berkorelasi dengan berbagai pekerjaan/role. Analisis dilakukan berdasarkan distribusi skor dimensi RIASEC (Realistic, Investigative, Artistic, Social, Enterprising, Conventional). Dimensi ini mengacu pada teori pemilihan karir RIASEC (Holland Code Theory) yang mengklasifikasikan minat karir ke dalam enam tipe kepribadian.

Analisis yang dilakukan:

1. Statistik deskriptif skor RIASEC

Berdasarkan ringkasan statistik terhadap seluruh sampel pekerjaan, berikut distribusi skor untuk setiap dimensi kepribadian:

	R	I	A	S	E	C
count	68.000	68.000	68.000	68.000	68.000	68.000
mean	0.254	0.777	0.401	0.255	0.341	0.725
std	0.125	0.167	0.304	0.196	0.220	0.180
min	0.013	0.280	0.033	0.083	0.083	0.223
25%	0.167	0.667	0.167	0.083	0.167	0.579
50%	0.250	0.833	0.301	0.167	0.250	0.750

75%	0.333	0.917	0.688	0.354	0.500	0.835
max	0.583	1.000	1.000	0.917	0.917	1.000

Interpretasi:

Berdasarkan hasil statistik deskriptif, dimensi Investigative (I) memiliki rata-rata skor tertinggi, yaitu 0.777, diikuti Conventional (C), yaitu 0.725. Ini menunjukkan bahwa mayoritas pekerjaan/role dalam dataset cenderung membutuhkan kemampuan analitis, problem solving, serta pola kerja yang sistematis dan terstruktur. Sebaliknya, dimensi Realistic (R) dan Social (S) memiliki rata-rata lebih rendah, mengindikasikan bahwa aktivitas fisik maupun interaksi sosial intensif bukan karakteristik utama pada sebagian besar role di dalam dataset ini.

2. Dimensi RIASEC dominan pada tiap pekerjaan/role

Untuk melihat dimensi mana yang bertindak sebagai kepribadian utama (skor tertinggi) di masing-masing role, berikut jumlah kemunculannya:

dimensi	count
I	38
C	13
A	11
E	5
S	1


Interpretasi:

Berdasarkan hasil eksplorasi, Investigative (I) mendominasi sebagian besar pekerjaan/role (38 role), diikuti Conventional (C) (13 role) dan Artistic (A) (11 role). Ini menunjukkan bahwa mayoritas role dalam dataset, khususnya di

bidang digital dan teknologi, lebih menekankan kemampuan berpikir logis, analitis, serta ketelitian.

3. Visualisasi distribusi rata-rata skor RIASEC

Untuk menjawab pertanyaan bisnis mengenai bagaimana perbandingan distribusi skor RIASEC antar peran ini terlihat secara visual, berikut grafik batang rata-rata skornya:



Interpretasi dan Kesimpulan Aplikatif:

Terlihat bentuk grafik yang melonjak tinggi pada pilar I dan C, melandai di pilar A dan E, dan terendah pada pilar R dan S. Bagi pengembangan platform, data distribusi ini dijadikan sebagai basis pembobotan dalam algoritma sistem rekomendasi. Ketika pengguna menjawab pertanyaan tes minat yang memiliki pembobotan, sistem dapat mencocokkannya dengan akurat ke pekerjaan/role yang memiliki profil RIASEC serupa, sehingga rekomendasi karir yang dihasilkan platform menjadi lebih valid.

5.4 Analisis Learning Resources

Eksplorasi ini bertujuan untuk memahami karakteristik sumber pembelajaran yang akan direkomendasikan kepada pengguna. Analisis ini dilakukan terhadap jumlah tahapan roadmap, platform pembelajaran, serta tipe resource yang digunakan.

Analisis yang digunakan:

1. Distribusi jumlah step roadmap

Analisis ini dilakukan untuk melihat seberapa banyak tahapan belajar yang harus dilalui pengguna untuk bisa menguasai suatu pekerjaan/role tertentu.

step_number	count
5	66
4	1
3	1

Interpretasi:

Berdasarkan tabel, mayoritas pekerjaan/role di dalam dataset sebanyak 66 role memiliki alur pembelajaran sepanjang 5 tahapan (steps). Pola ini mengindikasikan bahwa kurikulum upskilling yang dirancang dalam sistem memiliki struktur yang konsisten dan komprehensif.


2. Distribusi jumlah setiap platform pembelajaran

Bagian ini menganalisis platform mana saja yang paling dominan digunakan sebagai sumber materi pembelajaran dalam dataset.

platform	count	persentase (%)
Coursera	880	90,07%
Udemy	73	7,47%
Dicoding	18	1,84%

edX	6	0,6%
Total	977	100%

Untuk melihat perbandingan frekuensi kemunculan antar platform penyedia sumber pembelajaran, berikut visualisasi distribusinya:



Interpretasi:

Berdasarkan hasil eksplorasi dan visualisasi, dapat dilihat dominasi dari Coursera yang mencakup 90,07% dari total seluruh materi (880 materi). Posisi kedua Udemy (7,47%), diikuti oleh Dicoding (1,84%), dan edX (0,61%) di posisi terakhir. Ini membuktikan bahwa basis data kurikulum sangat mengandalkan Coursera sebagai pilar utama kursus global, namun tetap menyertakan Dicoding untuk mengakomodasi kebutuhan materi berbahasa Indonesia yang sudah terspesialisasi dengan industri lokal. Dominasi Coursera menunjukkan bahwa mayoritas sumber pembelajaran mengarah pada platform kursus global yang menyediakan materi terstruktur dan sertifikasi profesional.

3. Distribusi tipe resource pembelajaran

Analisis ini ditujukan untuk mengetahui media belajar yang akan diterima pengguna pada suatu roadmap upskilling:

tipe	count
Video Course + Certificate	959
Interactive Course + Certificate	18

Interpretasi:

Berdasarkan hasil eksplorasi, Video Course + Certificate menjadi tipe media belajar yang mendominasi dengan total 959 konten, sementara tipe media belajar Interactive Course + Certificate berjumlah 18 konten. Ini menandakan bahwa sistem rekomendasi nantinya akan mengarahkan pengguna pada pembelajaran berbasis video pembelajaran mandiri yang dikombinasikan dengan benefit sertifikasi digital sebagai bukti kelulusan. Karakteristik materi ini sangat cocok untuk pengguna yang membutuhkan fleksibilitas waktu belajar, namun tetap mendapatkan pengakuan kredibilitas profesional di akhir kursus.

5.5 Analisis Dummy Projects

Eksplorasi pada bagian ini dilakukan untuk memahami karakteristik proyek simulasi yang disediakan sebagai media praktik mandiri bagi pengguna. Analisis dilakukan terhadap variasi proyek serta tools yang digunakan untuk mendukung pengembangan skill secara praktikal.

Analisis yang dilakukan:

1. Jumlah kemunculan setiap tools

Bagian ini menganalisis perangkat lunak atau teknologi apa saja yang paling sering dipakai dalam proyek simulasi.

tools_used	count
Python	7
Figma	4
Draw.io	4
MySQL	3
Unity	3
SQL	3
Excel	3
Notion	3
OpenAI API	2
AWS	2

Untuk melihat pemetaan 10 perangkat teknologi yang paling mendominasi praktik dalam dataset, berikut visualisasinya:



Interpretasi:

Berdasarkan hasil eksplorasi, Python menduduki posisi pertama sebagai tool yang paling banyak digunakan (muncul di 7 proyek), diikuti Figma (4 proyek), dan [Draw.io](#) (4 proyek). Informasi ini memberikan petunjuk konkret bagi pengguna mengenai perangkat esensial yang harus mereka pelajari.

2. Jumlah tools setiap dummy project

Analisis ini ditujukan untuk mengukur tingkat kompleksitas teknis dari setiap proyek simulasi berdasarkan banyaknya kombinasi perangkat teknologi yang harus digunakan.

role_id	jumlah_tools
R001	3
R002	2
R003	3
R004	1
R005	2
R006	3
R007	2
R008	2
R009	2
R010	2

Interpretasi:

Mayoritas proyek simulasi dirancang dengan melibatkan 2 hingga 3 kombinasi tools sekaligus, sementara yang lain hanya membutuhkan 1 tool dasar. Ini mengindikasikan bahwa dummy project mendorong pengguna untuk menguasai tidak hanya satu tool saja.

6. Feature Engineering & Final Dataset

Pada tahap ini dilakukan feature engineering untuk mempersiapkan data agar dapat digunakan pada tahap pemodelan sistem rekomendasi karir. Tujuan utama dari tahap ini adalah menggabungkan informasi dari beberapa dataset serta mengubah fitur kategorikal menjadi representasi numerik yang dapat diproses oleh model machine learning.

6.1 Normalisasi kolom 'skill'

Kolom skill berisi daftar skill yang berasal dari berbagai sumber dan berpotensi memiliki perbedaan penulisan akibat penggunaan huruf kapital maupun variasi format. Oleh karena itu, dilakukan normalisasi dengan mengubah seluruh nama skill menjadi huruf kecil (lowercase).

Contoh:

Sebelum	Sesudah
['SQL', 'Java', 'Python', 'Git', 'JavaScript', 'HTML', 'CSS', 'React', 'Agile', 'Docker']	['sql', 'java', 'python', 'git', 'javascript', 'html', 'css', 'react', 'agile', 'docker']

Setelah proses normalisasi dilakukan, seluruh skill memiliki format penulisan yang konsisten sehingga mengurangi duplikasi fitur akibat perbedaan kapitalisasi.

6.2 Penggabungan Data RIASEC dan Informasi Role

Dataset `roles_df` menyimpan informasi skor RIASEC untuk setiap pekerjaan/role, sedangkan dataset `master_roles_df` menyimpan informasi deskripsi, skill, dan gaji. Agar seluruh informasi berada dalam satu tabel yang terintegrasi, kedua dataset digabung berdasarkan kolom `role_id`.

Proses penggabungan dilakukan menggunakan metode left join dengan `role_id` sebagai kunci utama.

Dataset hasil penggabungan (master_feature_df) memiliki 68 baris dan 12 kolom yang terdiri atas:

- Informasi role (role_id, field_id, deskripsi)
- Informasi skill
- Informasi gaji
- Jumlah skill (jumlah_skill)
- Skor RIASEC (R, I, A, S, E, C)

Dengan penggabungan ini, setiap role memiliki representasi yang lebih lengkap untuk digunakan pada proses rekomendasi.

6.3 Multi-Hot Encoding Kolom 'skill'

Kolom skill masih berupa data teks yang berisi daftar skill untuk setiap role. Format tersebut tidak dapat digunakan secara langsung pada proses pemodelan. Oleh karena itu, dilakukan transformasi menggunakan metode Multi-Hot Encoding.

Setiap skill unik diubah menjadi kolom biner:

- Nilai 1 menunjukkan bahwa role memiliki skill tersebut.
- Nilai 0 menunjukkan bahwa role tidak memiliki skill tersebut.

Sebagai contoh:

Pekerjaan/Role	Python	Figma	SQL
Data Analyst	1	0	1
UI/UX Designer	0	1	0

Dari proses encoding diperoleh:

- Total role: 68
- Total skill unik: 436
- Total kolom pada dataset: 448

Dataset hasil akhir disimpan dalam file master_feature_final.csv dan digunakan sebagai input utama pada tahap pemodelan sistem rekomendasi karir CareerLens.

6.4 Struktur Dataset Final

Dataset akhir (master_feature_final.csv) merupakan hasil integrasi seluruh fitur yang relevan, meliputi:

- Informasi role
- Deskripsi role
- Informasi gaji
- Jumlah skill
- Skor RIASEC
- Representasi biner dari 436 skill unik

Dataset ini digunakan sebagai dasar perhitungan kemiripan (similarity) dan proses rekomendasi karir pada tahap modelling.

7. A/B Testing

Tahap pengujian ini dilakukan untuk mengevaluasi efisiensi sistem dan kualitas keluaran dari pembaruan database kurikulum pembelajaran secara objektif. Eksperimen ini bertujuan untuk memvalidasi apakah proses pembersihan data (data cleaning) berskala besar pada sumber belajar mampu meningkatkan performa kecepatan backend sekaligus memangkas rekomendasi kurikulum yang tidak relevan.

7.1 Desain Eksperimen

Eksperimen dijalankan dalam lingkungan simulasi terkontrol (Control Simulation Testing) dengan mengeksekusi 50 kombinasi kata kunci atau keahlian (user query/skills) unik yang merepresentasikan seluruh variasi klaster profesi pada berkas basis data roles.csv. Pengujian ini membagi arsitektur pembacaan sumber belajar ke dalam dua varian eksperimen.

- Varian A (Control): Sistem rekomendasi membaca database lama learning_resources_OLD.csv yang masih mengandung data kotor dan kurikulum luar domain.
- Varian B (Treatment): Sistem rekomendasi membaca database baru learning_resources_ULTIMATE.csv yang telah melalui proses kurasi, pembersihan, dan standarisasi terintegrasi.

7.2 Hipotesis Pengujian dan Metrik Evaluasi

Metrik evaluasi yang dipantau dalam eksperimen berbasis sumber belajar ini difokuskan pada dua indikator performa utama, yaitu:

1. Noise Reduction (Kualitas): Jumlah kemunculan materi atau kursus non-IT/luar domain yang menyusup ke dalam sistem ketika diuji menggunakan sampel kata kunci keahlian.
2. Latency (Efisiensi): Kecepatan waktu respons internal algoritma backend saat memindai kata kurikulum dalam memori lokal (dihitung dalam milidetik menggunakan pustaka time Python).

Hipotesis statistik yang diuji dalam penelitian ini ditetapkan sebagai berikut:

- H0 (Null Hypothesis): Tidak ada perbedaan signifikan pada rata-rata jumlah kursus dan latency antara varian A dan varian B.
- H1 (Alternative Hypothesis): Terdapat perbedaan signifikan pada rata-rata jumlah noise kursus dan latency setelah menggunakan varian B.
- Tingkat Signifikansi (α): 0,05 (Tingkat kepercayaan 95%).

7.3 Hasil Analisis Statistik dan Temuan Utama

Eksperimen yang dilakukan terhadap 50 sampel berpasangan berhasil mencatat ringkasan metrik evaluasi secara komprehensif pada tabel berikut:

Metrik Evaluasi	Varian A (Control)	Varian B (Treatment)	Perubahan (%)	P-Value	Kesimpulan Statistik
Rata-rata Noise	4,72 courses	0,54 courses	-88,56%	0,000000	Tolak H0 (Signifikan)
Rata-rata Latency	157,19 ms	109,08 ms	-30,61%	0,000000	Tolak H0 (Signifikan)

1. Evaluasi Kualitas Rekomendasi (Noise Reduction)

- Alasan Langkah Teknis: Pembersihan data kurikulum dari noise luar domain sangat krusial karena rekomendasi materi belajar yang tidak

relevan dapat mengaburkan akurasi roadmap upskilling dan membingungkan pengguna.

- Temuan Analisis: Proses pembersihan data secara masif pada varian B berhasil menekan kemunculan kursus yang tidak relevan secara drastis. Rata-rata noise terpangkas dari 4,72 kursus per pencarian menjadi hanya 0,54 kursus pada varian B (Efisiensi kebersihan sebesar 88,56%). Melalui uji Paired T-Test, diperoleh nilai P-Value = 0,000000 ($P < 0,05$), yang berarti keputusan statistik adalah Tolak H_0 . Pengukuran kekuatan efek (Effect Size) menggunakan metode Cohen menunjukkan hasil Sangat Besar (Large Effect Size). Penurunan kontaminasi data ini memberikan kepastian ilmiah bahwa pengguna platform hanya akan mendapatkan rekomendasi materi kompetensi yang benar-benar relevan dengan karir pilihan mereka.

2. Evaluasi Efisiensi Sistem (Latency)

- Alasan Langkah Teknis: Pengukuran latensi pemrosesan internal backend bertujuan untuk memastikan query pencarian materi belajar berjalan cepat, guna menjaga kenyamanan interaksi pengguna saat memuat halaman roadmap.
- Temuan Analisis: Varian B menunjukkan peningkatan efisiensi performa komputasi backend yang baik. Waktu respons rata-rata (average latency) berhasil dipangkas 157,19 ms pada varian A menjadi 109,08 ms pada varian B, atau berhasil menghemat waktu pemrosesan sebesar 30,61%. Nilai P-Value = 0,000000 ($P < 0,05$) menegaskan bahwa performa varian B ini dipengaruhi oleh struktur dataset ULTIMATE yang lebih rapi, bukan faktor kebetulan (random chance). Standarisasi dataset ini terbukti secara signifikan meringankan beban input/output (I/O) memori saat fungsi backend melakukan pemindaian data.

7.4 Batasan Cakupan Eksperimen (Scope Limitation)

Untuk menjaga objektivitas hasil pengujian, terdapat beberapa batasan konteks eksperimen:

1. Synthetic User Query: Pengujian dilakukan dalam lingkungan simulasi terkontrol menggunakan variasi kata kunci riil dari repositori keahlian lokal. Langkah ini diambil untuk mengantisipasi ketiadaan trafik pengguna aktif pada fase pra-rilis (pre-release phase).
2. Internal Engine Latency: Metrik kecepatan waktu respons (latency) yang dicatat merupakan durasi pemrosesan internal pada unit fungsi algoritma backend di memori lokal, sehingga belum mencakup hambatan eksternal seperti Network Round-Trip (RTT) dari peladen web hosting ke sisi klien/antarmuka pengguna (frontend).

8. Kesimpulan Hasil Analisis

Berdasarkan seluruh rangkaian eksplorasi data (Exploratory Data Analysis) dan rekayasa fitur (feature engineering) yang telah dilakukan pada dataset platform CareerLens, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Karakteristik Finansial:

- Nilai rata-rata (mean) gaji di industri digital pada dataset ini berada pada angka Rp 8,09 juta per bulan, dengan median sebesar Rp 7,57 juta. Sebaran data ini memiliki outlier positif dengan gaji tertinggi mencapai Rp 27,26 juta.
- Rumpun bidang Data Science & Artificial Intelligence (F02) memiliki rata-rata gaji tertinggi, yaitu mencapai Rp 11,04 juta per bulan, disusul rumpun bidang Teknologi Informasi (F01) sebesar Rp 7,99 juta.
- Di tingkat peran spesifik, posisi Data Modeler (R040) teridentifikasi sebagai pekerjaan/role yang memiliki nilai gaji tertinggi di dalam grafik sebaran data.

2. Karakteristik Kepribadian Kerja (RIASEC):

- Rumpun pekerjaan/role digital dan teknologi didominasi oleh dimensi kepribadian Investigative (I) dengan rata-rata skor tertinggi 0,777 dan dominan pada 38 pekerjaan/role.
- Posisi kedua ditempati oleh dimensi Conventional (C) dengan rata-rata skor 0,725 dan dominan pada 13 pekerjaan/role.

- Kombinasi dominasi ini membuktikan bahwa industri digital menuntut talenta yang memiliki kemampuan berpikir logis, analitis, problem solving, serta kecenderungan bekerja secara sistematis, terstruktur, dan penuh ketelitian. Sebaliknya, dimensi Social (S) dan Realistic (R) memiliki signifikansi terendah di industri ini.

3. Karakteristik Sumber Pembelajaran (Learning Resources):

- Kurikulum pembelajaran untuk jalur karir (roadmap upskilling) pengguna konsisten, di mana 66 data 68 role dirancang secara merata ke dalam 5 tahapan (steps) kompetensi.
- Penyediaan materi didominasi oleh platform internasional Coursera, yang mencakup 90,07% (880 materi) dari total keseluruhan sumber belajar.
- Format/tipe konten pembelajaran yang disediakan didominasi oleh jenis Video Course + Certificate (959 konten), yang menunjukkan bahwa jalur upskilling menekankan fleksibilitas waktu belajar mandiri yang juga memiliki validasi sertifikat profesional.

4. Karakteristik Proyek Simulasi (Dummy Projects):

- Python menjadi tool teknologi yang paling krusial dan paling banyak diadopsi karena muncul di dalam 7 proyek simulasi utama, disusul oleh Figma (4 proyek) dan [Draw.io](https://draw.io) (4 proyek).
- Struktur pengerjaan proyek simulasi dirancang secara kompleks dalam multi-tooling environment, dimana mayoritas pekerjaan/role menuntut pengguna untuk mampu menggunakan 2 hingga 3 perangkat teknologi sekaligus untuk menyelesaikan satu studi kasus proyek.

5. Kesiapan Data Hasil Rekayasa Fitur:

- Rangkaian proses feature engineering berhasil mentransformasi data tekstual skill menjadi representasi numerik biner.
- Proses ini menghasilkan dataset final (master_feature_final.csv) dengan dimensi 68 baris (pekerjaan/role) dan 448 kolom yang merepresentasikan kombinasi fitur pekerjaan, deskripsi, gaji, skor

RIASEC, serta 436 kolom skill unik. Dataset final ini telah tervalidasi dan siap digunakan sebagai matriks input matematis pada tahap pemodelan sistem rekomendasi.

9. Rekomendasi Action Item

Berdasarkan kesimpulan hasil analisis data, disusun beberapa rekomendasi tindakan (action items) bagi pengembangan platform sistem rekomendasi karir CareerLens:

1. Mengembangkan sistem rekomendasi karir berbasis kombinasi skor RIASEC dan kemiripan skill untuk membantu pengguna menemukan pekerjaan/role yang sesuai dengan minat dan kompetensinya.
2. Menyediakan roadmap pembelajaran yang terhubung dengan role yang direkomendasikan untuk membantu pengguna menutup kesenjangan kompetensi antara skill yang dimiliki dan skill yang dibutuhkan industri serta memiliki panduan upskilling yang jelas.
3. Menampilkan estimasi gaji pada setiap rekomendasi karir untuk membantu pengguna mempertimbangkan prospek finansial dari jalur karir yang dipilih.
4. Mengintegrasikan proyek simulasi (dummy project) sebagai sarana praktik dan pembangunan portofolio yang mendukung kesiapan kerja pengguna.
5. Memanfaatkan dataset hasil feature engineering (master_feature_final.csv) sebagai dasar pengembangan model rekomendasi karir berbasis cosine similarity untuk menghasilkan rekomendasi yang lebih relevan.
6. Mewajibkan arsitektur backend produksi untuk menggunakan berkas learning_resources_ULTIMATE.csv sebagai repository tunggal sumber belajar. Berdasarkan hasil eksperimen CST pada tahap A/B Testing, penggunaan database hasil kurasi ini terbukti secara signifikan mampu memotong waktu respons (latency) sebesar 30,61% serta mereduksi noise sebesar 88,56%.

10. Daftar Pustaka

The Job Mismatch Problem: Mengapa Banyak Lulusan Sulit Dapat Kerja, Tapi Banyak

Perusahaan Mengeluh Kekurangan SDM? (2025, October 27th). Retrieved June

4th, 2026, from <https://www.talent.univeral.ac.id/detail/nea.php?aid=a0002>

RIASEC. *PENDETEKSIAN MINAT DAN BAKAT MENGGUNAKAN METODE RIASEC.*

<https://scispace.com/pdf/pendeteksian-minat-dan-bakat-menggunakan-metode-riasec-56kzleghr1.pdf>

Tingkat Pengangguran Terbuka (TPT) sebesar 4,85 persen. Rata-rata upah buruh

sebesar 3,33 juta rupiah. (2025, November 5). Badan Pusat Statistik. Retrieved

June 2, 2026, from

<https://www.bps.go.id/id/pressrelease/2025/11/05/2479/tingkat-pengangguran-terbuka--tpt--sebesar-4-85-persen--rata-rata-upah-buruh-sebesar-3-33-juta-rupiah-.html>